

تشخیص کلاه ایمنی

گزارش فنی پروژه بر اساس متدولوژی CRISP-DM

نام و نام خانوادگی: محمدحسین دادخواه

تاریخ: مرداد ۱۴۰۵

لینک ریپازتوری گیت‌هاب:

<https://github.com/MHDadkhah172/HelmetDetection>

1	مقدمه	2
2	ورک فلو و ساختار پروژه	3
2.1	متدولوژی CRISP-DM	3
3	درک مسئله	4
4	شناخت داده‌ها (DATA UNDERSTANDING):	5
4.1	مشخصات دیتاست	5
5	آماده سازی داده‌ها (DATA PREPARATION):	6
6	مدل سازی (MODELING):	7
6.1	علت انتخاب YOLO11 Nano	7
6.2	انتقال یادگیری (Transfer Learning):	7
6.3	جدول های پیرامترها (Hyperparameters):	7
7	ارزیابی مدل (MODEL EVALUATION):	8
7.1	تعیین آستانه اطمینان (Confidence Threshold Analysis):	8
7.2	چالش ناهمگونی داده‌ها (Data Imbalance Analysis):	8
7.3	تحلیل شاخص‌های کلیدی	9
8	استنتاج روی تصاویر واقعی (REAL-WORLD INFERENCE):	10
8.1	کشف خطای وابستگی رنگی (Color Bias)	10
9	پیشنهادهای توسعه: معماری دو مرحله‌ای (TWO-STAGE CASCADE ARCHITECTURE):	11
10	جمع‌بندی	12

1 مقدمه

پایش خودکار الزامات ایمنی فردی (HSE) در محیط‌های کارگاهی و صنعتی، یکی از کاربردهای کلیدی بینایی ماشین در راستای کاهش حوادث جانی است. در این پروژه، یک سیستم هوشمند جهت تشخیص لحظه‌ای استفاده از کلاه ایمنی با بهره‌گیری از معماری عمیق YOLO11 و بر پایه متدولوژی استاندارد CRISP-DM طراحی و ارزیابی شده است.

ساختار این گزارش منطبق بر چرخه مهندسی پروژه تدوین گردیده است؛ ابتدا به تعریف مسئله، ابعاد کسب‌وکار و اهداف پروژه پرداخته می‌شود. سپس مراحل شناخت توزیع داده‌ها، پیش‌پردازش و تکنیک‌های افزایش داده (Augmentation) تشریح می‌گردند. در ادامه، پیکربندی مدل YOLO11 و فرآیند آموزش بررسی شده و متعاقباً شاخص‌های عملکرد، تحلیل ناهمگونی داده‌ها (Data Imbalance) و Confusion Matrix در ارزیابی تحلیل می‌شوند. در بخش پایانی نیز تست‌های تصاویر واقعی، چالش‌های عملیاتی (مانند Color Bias) و راهکارهای توسعه سیستم ارائه شده‌اند.

2 ورک فلو و ساختار پروژه

2.1 متدولوژی CRISP-DM

برای اجرای مهندسی و ساختاریافته این پروژه، از استاندارد صنعت داده یعنی **CRISP-DM** استفاده شده است. ورک فلو پروژه شامل مراحل زیر است:

1. **درک مسئله کسب و کار (Business Understanding):** تحلیل مسئله، بررسی اهمیت رعایت ایمنی در محیط‌های صنعتی و تعیین اهداف و معیارهای موفقیت پروژه.
2. **شناخت داده‌ها (Data Understanding):** دریافت دیتاست از Roboflow، بررسی کلاس‌ها، توزیع داده‌ها و ارزیابی اولیه کیفیت داده‌ها.
3. **آماده‌سازی داده‌ها (Data Preparation):** آماده‌سازی دیتاست برای آموزش مدل شامل تقسیم داده‌ها، اعمال افزایش داده (Data Augmentation) و تنظیم ساختار استاندارد YOLO.
4. **مدل‌سازی و آموزش (Modeling):** انجام Fine-tuning مدل از پیش‌آموزش دیده YOLO11n، تنظیم هایپرپارامترها و آموزش مدل روی پردازنده گرافیکی (GPU).
5. **ارزیابی مدل (Model Evaluation):** ارزیابی عملکرد مدل با استفاده از معیارهای Precision، Recall، mAP و Confusion Matrix و تحلیل نتایج روی دیتاست Test.
6. **استنتاج روی تصاویر واقعی (Real-World Inference):** آزمایش مدل روی تصاویر جدید و دیده‌نشده به منظور بررسی عملکرد آن در شرایط نزدیک به محیط واقعی.
7. **تحلیل نتایج و پیشنهادهای توسعه (Future Improvements & Analysis):** بررسی محدودیت‌های مدل، تحلیل خطاها، شناسایی سوگیری رنگی (Color Bias) و ارائه پیشنهادهایی برای بهبود عملکرد، از جمله معماری دو مرحله‌ای (Two-Stage Pipeline).

3 درک مسئله

3.1 اهمیت ایمنی در محیط‌های صنعتی

تجهیزات حفاظت فردی (Personal Protective Equipment - PPE) و به‌ویژه کلاه ایمنی، اصلی‌ترین ابزار جهت جلوگیری از آسیب‌های فیزیکی شدید و حوادث منجر به فوت در محیط‌های ساختمانی، کارگاهی، پالایشگاهی و معدنی محسوب می‌شوند. بر اساس استانداردهای بهداشت، ایمنی و محیط زیست (HSE)، حضور تمامی نیروهای کار بدون کلاه ایمنی در محدوده عملیاتی ممنوع است.

3.2 چالش‌های نظارت سنتی

نظارت دستی و چشمی روی رعایت اصول ایمنی توسط ناظران انسانی همیشه کارآمد نیست. این روش با چالش‌های ساختاری زیر روبرو است:

- **خطای انسانی و خستگی:** عدم امکان تمرکز مداوم ناظران در شیفت‌های کاری طولانی.
- **کوری زاویه‌ای (Blind Spots):** عدم پوشش کامل تمام نقاط کارگاه‌های وسیع یا چندطبقه.
- **هزینه‌های بالای پایش:** نیاز به جذب نیروهای نظارتی متعدد و صرف زمان زیاد.

3.3 هدف پروژه

هدف از این پروژه، طراحی و توسعه یک سیستم هوشمند بینایی ماشین (Computer Vision) با استفاده از **YOLO11** است تا فرآیند پایش تصاویر ویدئویی را به صورت خودکار و لحظه‌ای (Real-time) انجام دهد. سیستم باید حضور نیروهای کار را بررسی کرده و دو کلاس اصلی را از هم تفکیک کند:

1. **helmet:** فرد دارای کلاه ایمنی استاندارد (وضعیت ایمن).


2. **head:** سر بدون کلاه ایمنی (وضعیت خطر / عدم رعایت HSE).

4 شناخت داده‌ها (Data Understanding):

4.1 مشخصات دیتاست¹

دیتاست مورد استفاده در این پروژه از پلتفرم **Roboflow** استخراج شده است. پس از دریافت و ارزیابی اولیه کیفیت داده‌ها، مشخص شد این دیتاست سه کلاس به نام‌های زیر دارد:

1. head: سر بدون کلاه
2. helmet: کلاه ایمنی
3. person: تشخیص کلی پیکر انسان



شکل 3-1 توزیع داده‌ها



شکل 3-2 دو نمونه از تصاویر دیتاست

¹ <https://universe.roboflow.com/joseph-nelson/hard-hat-workers/dataset/11>

5 آماده سازی داده‌ها (Data Preparation):

مجموعه داده دریافت شده از Roboflow به سه قسمت train, valid, test تقسیم شده بودند. که اندازه هر کدام از قسمت‌ها به شرح زیر است:

بخش داده‌ها (split)	تعداد تصاویر (images)	درصد از کل
Train Set	۱۴,۷۴۸	۸۸%
Valid Set	۱,۴۱۳	۸%
Test Set	۷۰۶	۴%
مجموع کل	۱۶,۸۶۷	۱۰۰%

جدول 4-1: مشخصات تفکیک مجموعه داده (Dataset Split) و تعداد تصاویر هر بخش

جهت افزایش تنوع تصویری، کاهش Overfitting و بالا بردن توانایی تعمیم‌دهی مدل در شرایط سخت کارگاهی، به صورت پیش‌فرض از تکنیک‌های **Data Augmentation** استفاده شده بود. در این دیتاست، به ازای هر تصویر اصلی، چند تصویر جدید با تغییرات تصادفی تولید شده است که مشخصات آن به شرح زیر است:

• ویژگی‌های هندسی و مکانی (Geometric Features):

- Flip: Horizontal
- Crop: 0% Minimum Zoom, 20% Maximum Zoom
- Rotation: Between -10° and $+10^{\circ}$
- Grayscale: Apply to 10% of images
- Hue: Between -20° and $+20^{\circ}$
- Saturation: Between -25% and +25%
- Brightness: Between -20% and +20%
- Exposure: Between -20% and +20%
- Blur: Up to 1px
- Cutout: 6 boxes with 3% size each

ساختاردهی مجموعه داده بر پایه فرمت استاندارد YOLO انجام شد و کلیه پیکربندی‌های مربوط به مسیر فایل‌ها و تعریف کلاس‌ها به وسیله فایل data.yaml به مدل اختصاص یافت.

6 مدل سازی (Modeling):

6.1 علت انتخاب YOLO11 Nano:

در سیستم‌های پایش ایمنی صنعتی، سرعت پردازش بالا (High FPS) و امکان اجرا روی دستگاه‌های Edge (مانند پردازنده‌های داخلی دوربین‌های مداربسته) اهمیت بالایی دارد. معماری YOLO11n به دلیل تعادل فوق‌العاده میان دقت، نرخ فریم بالا و حجم کم مدل انتخاب شد.

6.2 انتقال یادگیری (Transfer Learning):

به جای آموزش مدل از صفر، از وزن‌های پیش‌آموزش‌دیده (Pre-trained) شبکه روی مجموعه داده COCO بهره گرفته شد. این کار باعث شد مدل ویژگی‌های پایه بینایی (لبه‌ها، رنگ‌ها و بافت‌ها) را از قبل شناخته باشد و فرآیند آموزش مستقیماً روی ویژگی‌های تخصصی کلاه و سر متمرکز شود.

6.3 جدول هایپرپارامترها (Hyperparameters):

پارامتر	مقدار تنظیم‌شده	توجیه فنی
معماری شبکه	YOLO11 Nano	بهینه‌شده برای نرخ فریم بالا و اجرا روی Edge
ابعاد تصویر ورودی	640 × 640	ابعاد استاندارد برای حفظ جزئیات اشیاء کوچک
تعداد Epochs	۱۵	همگرایی مناسب Loss بدون بروز Overfitting
Batch Size	۱۶	بهینه‌سازی بهره‌وری حافظه GPU
محیط پردازشی	Google Colab (GPU T4)	شتاب‌دهی سخت‌افزاری پردازش

7 ارزیابی مدل (Model Evaluation):

7.1 تعیین آستانه اطمینان (Confidence Threshold Analysis):

پیش از بررسی شاخص‌های عملکرد و استخراج جداول ارزیابی، آستانه اطمینان (conf) مدل بر اساس منحنی **F1-Confidence** (شکل 6-1) تنظیم گردید. آستانه اطمینان تعیین می‌کند که مدل تنها کادرهایی (Bounding Boxes) را به عنوان خروجی نهایی بپذیرد که درصد اطمینان پیش‌بینی آن‌ها از یک حد مشخص بالاتر باشد.

با تحلیل نقطه اوج منحنی F1-Curve (توازن بهینه میان Precision و Recall)، مقدار آستانه روی $\text{conf} = 0.35$ جهت استنتاج نهایی و محاسبه شاخص‌های ارزیابی تنظیم گردید.

7.2 چالش ناهمگونی داده‌ها (Data Imbalance Analysis):

در فاز ارزیابی روی مجموعه داده Test، مشخص شد کلاس person تنها دارای ۶۴ نمونه است. این حجم کم داده باعث شد مدل نتواند الگوهای بدن انسان را یاد بگیرد ($mAP = 0.0$) و معدل کل تمام کلاس‌ها افت پیدا کند.

از آنجا که هدف اصلی سیستم، بررسی رعایت ایمنی (کلاه و سر) است، ارزیابی در دو سطح گزارش می‌شود:

1. نتایج ارزیابی خام (تمامی ۳ کلاس):

کلاس	تعداد نمونه‌ها	Precision	Recall	mAP@50	mAP@50-95
head	۷۲۶	۰.۹۴۸	۰.۹۲۲	۰.۹۳۵	۰.۶۴۹
helmet	۱۹۱۵	۰.۹۵۶	۰.۹۴۰	۰.۹۵۱	۰.۶۶۰
person	۶۴	۰.۰۰۰	۰.۰۰۰	۰.۰۰۰	۰.۰۰۰
معدل کل (All Classes)	۲۷۰۵	۰.۶۳۵	۰.۶۲۱	۰.۶۲۹	۰.۴۳۶



2. نتایج ارزیابی واقعی (کلاس‌های اهداف ایمنی):

با حذف کلاس کم‌تعداد person و تمرکز بر اهداف اصلی (helmet , head) عملکرد فوق‌العاده مدل شفاف می‌شود:

کلاس	تعداد نمونه‌ها	Precision	Recall	mAP@50	mAP@50-95
head	۷۲۶	۰.۹۴۸	۰.۹۲۲	۰.۹۳۵	۰.۶۴۹
helmet	۱۹۱۵	۰.۹۵۶	۰.۹۴۰	۰.۹۵۱	۰.۶۶۰
معدل اهداف	۲۶۴۱	۰.۹۵۲	۰.۹۳۱	۰.۹۴۳	۰.۶۵۵

7.3 تحلیل شاخص‌های کلیدی

- **دقت بالا روی اهداف اصلی ($mAP@50 = 94.3\%$):** مدل با ثبت این امتیاز، بسیار بالاتر از حد نصاب موفقیت اولیه (۸۰٪) قرار گرفت.
- **مرزبندی دقیق Bounding Box ها ($mAP@50 - 95 = 65.5\%$):** نشان‌دهنده انطباق بسیار دقیق کادرهای پیش‌بینی‌شده با مرزهای سر و کلاه است.
- **تحلیل ماتریس اغتشاش (Confusion Matrix):** مدل از مجموع ۷۲۶ نمونه سر بدون کلاه، تنها در ۳ مورد دچار خطای اشتباه با کلاه شده است. این نرخ بسیار پایین خطا برای سیستم‌های ایمنی حیاتی است.



شکل 6-1 F1 Curve (سمت راست) | شکل 6-2 confusion_matrix (سمت چپ)


8 استنتاج روی تصاویر واقعی (Real-World Inference):

در فاز ۶ تسک، اسکریپت `src/predict.py` روی تصاویری واقعی و دیده‌نشده اجرا شد.

8.1 کشف خطای وابستگی رنگی (Color Bias)

تحلیل کیفی خروجی‌ها روی تصاویر واقعی یک رفتار محدودکننده را آشکار ساخت:

- **مشکل مشاهداتی:** مدل روی کلاه‌های ایمنی سفید رنگ (شکل 8-1) نسبت به کلاه‌های زرد و آبی، آستانه اطمینان (Confidence) کمتری نشان می‌دهد یا در مواردی آن‌ها را نادیده می‌گیرد.
- **علت ریشه‌ای (Spurious Correlation):** به دلیل فراوانی بیشتر کلاه‌های زرد و آبی در داده‌های آموزشی، شبکه بخشی از مفهوم «کلاه» را با رنگ گره زده است.
- **راهکار اصلاحی:** در آموزش‌های بعدی باید از تکنیک **Grayscale Augmentation** استفاده شود تا بی‌رنگ کردن داده‌ها شبکه را مجبور کند صرفاً روی اشکال هندسی، لبه‌ها و بافت کلاه متمرکز شود.



شکل 8-1 نمونه‌هایی از تصاویر پردازش‌شده توسط مدل؛ در هر دو تصویر، مدل قادر به تشخیص صحیح کلاه ایمنی سفید رنگ نبوده و دچار خطا شده است.

9 پیشنهادات توسعه: معماری دو مرحله‌ای (Two-Stage Cascade Architecture)

برای استقرار صنعتی این سیستم و به صفر رساندن خطای مهلک (یعنی ندیدن یک کارگر بدون کلاه)، استفاده از به روش زیر به نظر بهتر است:

معماری پایپ‌لاین دو مرحله‌ای (Two-Stage Cascade Architecture):

1. ورودی سیستم: دریافت فریم‌های تصویری یا جریان ویدئویی زنده از دوربین مداربسته.

2. مرحله ۱ — مدل تشخیص انسان (Person Detector):

- تنظیمات: آستانه اطمینان پایین
- هدف اصلی: اولویت با **High Recall** است تا تحت هر شرایطی (نور کم، فاصله زیاد، اختفای نسبی)، تمام نیروهای کار موجود در تصویر شناسایی شوند و هیچ کارگری از دید سیستم پنهان نماند.
- خروجی: برش خودکار ناحیه بدن/سر نیروهای کار (Crop Person Region).

3. مرحله ۲ — مدل طبقه‌بندی کلاه و سر (Helmet/Head Classifier):

- تنظیمات: آستانه اطمینان بالا
- هدف اصلی: اولویت با **High Precision** است؛ یعنی بررسی دقیق نواحی برش‌خورده تا اجسام خارجی پیش‌زمینه (مثل کپسول آتش‌نشانی، فرم سر، رنگ مو یا تجهیزات) به اشتباه به عنوان کلاه ایمنی شناسایی نشوند.
- خروجی نهایی: ثبت وضعیت ایمنی فرد (helmet یا head) و ارسال هشدار در صورت عدم رعایت HSE.

در ارزیابی سیستم‌های ایمنی صنعتی (HSE)، موازنه میان خطاهای مدل همیشه به نفع حفظ جان نیروی کار انجام می‌شود. به بیان دقیق‌تر، وقوع **خطای مثبت کاذب (False Positive)** به مراتب پذیرفته‌شده‌تر از **خطای منفی کاذب (False Negative)** است.

در این رویکرد، اگر سیستم به اشتباه یک فرد دارای کلاه را به عنوان فردی بدون کلاه طبقه‌بندی کند (افزایش هشدار کاذب)، خطای مهلکی رخ نداده است؛ اما اگر یک فرد بدون کلاه به اشتباه دارای کلاه تشخیص داده شود (**False Safety Classification**)، یک ریسک بحرانی و صدمه جانی جبران‌ناپذیر به همراه خواهد داشت.

10 جمع‌بندی

در این پروژه، پایپ‌لاین هوشمند پایش کلاه ایمنی بر اساس متدولوژی **CRISP-DM** و با تکیه بر معماری **YOLO11** پیاده‌سازی و ارزیابی شد. نتایج کلیدی پروژه را می‌توان در سه محور زیر خلاصه کرد:

- **عملکرد بالا در اهداف ایمنی:** مدل نهایی با تمرکز بر کلاس‌های هدفمند (helmet, head)، به شاخص $mAP@50 = 94.3\%$ و $Recall = 93.1\%$ دست یافت که نشان‌دهنده توانایی بالای آن در تفکیک سر بدون کلاه از کلاه ایمنی است.
- **شناسایی رفتارهای عملیاتی:** ارزیابی مدل روی داده‌های واقعی، وجود وابستگی رنگی (Color Bias) روی کلاه‌های سفید را آشکار ساخت که ریشه در توزیع داده‌های ورودی داشت.
- **نقشه راه توسعه صنعتی:** برای رفع محدودیت‌های موجود و کاهش خطاهای بحرانی در کاربردهای ایمنی، دو راهکار عملیاتی **Grayscale Augmentation** و پایپ‌لاین دو مرحله‌ای **(Two-Stage Cascade)** برای ارتقا به محصول صنعتی پیشنهاد شد.

در مجموع، این پروژه نشان داد که بهره‌گیری از یک فرآیند ساختاریافته مبتنی بر CRISP-DM، در کنار استفاده از مدل‌های از پیش‌آموزش‌دیده مانند YOLO11، می‌تواند در مدت‌زمان کوتاه به یک سامانه تشخیص کلاه ایمنی با عملکرد مناسب منجر شود. همچنین تحلیل محدودیت‌ها و ارائه راهکارهای توسعه، مسیر روشنی برای ارتقای این سامانه به یک راهکار قابل استفاده در محیط‌های صنعتی فراهم می‌کند.